

1. 문제 제기

AI 성능 저하의 원인은 항상 모델에 있지 않습니다

AI 성능이 기대에 미치지 못하면 일반적으로 모델 구조, 학습 방식, 하이퍼파라미터를 먼저 수정합니다. 그러나 객체탐지 모델은 학습데이터에 포함된 바운딩박스 위치 오류, 객체 누락, 잘못된 클래스와 같은 라벨 오류에도 민감하게 영향을 받습니다.

Schubert 등의 WACV 2024 연구에서는 BDD100K 객체탐지 학습데이터의 라벨 20%를 인위적으로 변형했을 때, 모델과 학습 조건이 동일함에도 mAP가 최대 3.9%p 감소했습니다. 이는 모델을 바꾸지 않아도 라벨 품질만으로 AI 성능이 유의미하게 하락할 수 있음을 보여줍니다.

또한 최근 연구에서는 객체 누락, 부정확한 바운딩박스과 같은 라벨 오류가 모델의 성능과 일반화 능력을 저하시킬 수 있으며, 품질이 낮은 재라벨링 과정은 기존 오류를 수정하기보다 오히려 새로운 오류를 더 많이 만들 수 있다고 지적합니다. 즉, 라벨 검수는 단순한 데이터 정리 작업이 아니라 모델 성능과 신뢰성을 결정하는 핵심 개발 단계입니다. (https://arxiv.org/abs/2508.06556?utm_source)

산업적으로 중요한 이유

라벨 오류가 포함된 상태에서 성능이 낮아지면 기업은 실제 원인이 데이터에 있음에도 불구하고 모델 구조를 수정하거나 반복 학습을 수행할 수 있습니다. 그 결과 다음 문제가 발생합니다.

- 불필요한 모델 재학습과 GPU 비용 증가
- 잘못된 원인 분석으로 인한 개발 일정 지연
- 전체 데이터 재검수와 재라벨링 비용 발생
- 납품 데이터의 품질과 모델 성능에 대한 신뢰 저하

따라서 AI 개발 현장에서는 단순히 "라벨에 오류가 있는가"를 확인하는 것을 넘어, 성능 저하가 모델 때문인지 데이터 라벨 때문인지 구분하고, 어떤 오류가 성능에 얼마나 영향을 주는지 확인할 수 있는 검증 수단이 필요합니다.

2. 기존 방식의 한계

라벨 오류가 포함된 데이터로 AI 모델을 학습하면 모델 성능과 평가 결과가 저하될 수 있습니다. 이 경우 기업은 오류의 원인이 데이터에 있음에도 모델 구조나 학습 설정을 반복적으로 수정하고, 모델을 다시 학습한 뒤 데이터 재검수와 재라벨링까지 수행할 수 있습니다.

현재 데이터 품질검수는 자동화 도구를 활용하더라도, 오류 후보를 사람이 확인하고 기존 라벨을 검증·수정하는 절차가 필요합니다. 특히 대규모 데이터셋에서 오류가 발생한 위치와 유형을 특정하지 못하면 검수 범위를 넓게 잡아야 하므로, 많은 시간과 인력이 소요될 수 있습니다. AWS Ground Truth 역시 라벨 품질 확보를 위해 작업자가 기존 라벨을 반복적으로 검증하고 조정하는 구조를 제공하고 있습니다. 따라서 기존 방식은 성능 저하의 원인이 되는 오류 유형과 검수 대상을 빠르게 좁히기 어렵다는 한계점이 존재합니다.

이로 인해 1) 불필요한 모델 재학습과 GPU 사용 2) 데이터 재검수 및 재라벨링 3) 개발 일정 지연 4) 이미 완료된 데이터 구축 작업의 반복에 대한 비용이 발생할 수 있습니다.

3. AIDA 소개

“AIDA는 객체탐지 학습데이터의 라벨 오류 가능성과 모델 성능 영향을 분석하여, 재검수 우선 순위와 품질검증 리포트를 제공하는 제3자 데이터 품질검증 플랫폼입니다.”


AIDA: AI Data Integrity Diagnosis & Assurance

AIDA는 검증 대상 데이터셋을 오류 유형별 기준 성능 패턴과 비교하여 다음 정보를 제공합니다.

- 가능성이 높은 라벨 오류 유형
- 오류 수준에 따른 모델 성능 영향
- 우선 재검수 대상
- 데이터 품질검증 리포트

AIDA는 “오류가 있는가?”를 넘어 “어떤 오류가 성능에 영향을 주며, 어디부터 다시 봐야 하는가?”를 제시합니다.

4. 국방기술 활용 및 기술 원리



AIDA는 국방특허인 ‘가상 이미지 데이터 기반의 학습데이터 검증 기술’의 핵심 원리를 민간 AI 데이터 품질검증 분야에 적용한 서비스이다. 해당 국방특허의 핵심 원리는 ‘가상 오류 데이터 생성 → 오류 조건별 모델 성능 패턴 구축 → 실제 데이터와 비교하여 오류 가능성 추정’ 구조이며 AIDA는 이를 자율주행 객체탐지 데이터 품질검증에 적용한 플랫폼이다. 초기 MVP에서는 KITTI Car 데이터셋의 기준 라벨에 IoU 기반으로 가로 길이, 세로 길이, 중심점 이동 오류를 주입하고, 동일한 YOLO 모델을 조건별로 학습·평가하여 오류 유형별 성능 패턴 DB를 구축한다. 이후 검증 대상 데이터셋의 성능 패턴을 기준 DB와 비교하여 가능성이 높은 오류 유형과 수준을 추정하고, 오류 후보, 성능 영향, 재검수 우선순위, 품질 리포트를 제공한다. 즉, AIDA는 데이터 오류를 자동 확정하는 시스템이 아니라, 성능에 영향을 줄 가능성이 높은 오류를 선별해 검수 범위를 줄여주는 데이터 품질검증 플랫폼이다.

5. MVP 구현 및 검증 계획

AIDA는 현재 아이디어 단계에 머무르지 않고, 실제 구현 가능성을 확인하기 위한 MVP를 구축했다. 공개 객체탐지 데이터셋(KITTI Car 클래스)을 기반으로 가로·세로 크기, 중심점 이동, 회전각, 스케일 등 오류 조건별 학습 데이터를 자동 생성하고, 동일한 초기 가중치·학습 조건에서 객체탐지 모델(YOLOv8n)을 21개 조건 전체 동일 50epoch로 반복 학습해 성능 변화를 실측했다.

그 결과 오류 유형과 강도에 따라 모델 성능이 서로 다르게 변화하는 패턴을 확인했다. 특히 회전각 오류가 가로·세로 오류보다 일관되게 크게 성능을 저하시켰고(mAP@0.5 최대 5.7% ↓, Recall 최대 6.4% ↓), Precision은 거의 변하지 않는 반면 Recall이 라벨 오류에 가장 민감하게 반응했다. 이 결과는 표와 그래프로 정리해 조건별 성능 데이터를 비교할 수 있는 구조로 구현했다. 다만 현재 결과는 조건당 1회 실행(단일 시드)에 기반하므로, 이 패턴이 순수한 오류 효과인지 학습 과정의 노이즈인지는 통계적으로 완전히 분리되지 않는다. 본선 진출 시 조건당 복수 시드 반복으로 통계적 유의성을 검증할 계획이다.

초기 웹 대시보드는 데이터셋 품질점수, ROI 절감 추정, 오류 조건별 성능 변화 그래프, 조건별 상세 지표(mAP·Precision·Recall·IoU 감소율), 재검수 우선순위, CSV 다운로드를 한 화면에서 제공하도록 구성했다. 이 화면은 실제 실험 결과(metrics.csv)를 그대로 반영하며, 코드 수정 없이 결과가 갱신되는 구조다. 향후에는 실제 고객 데이터셋 업로드 기능과 사용자 피드백을 반영해 UI를 고도화할 계획이다.



* MVP의 핵심 구성

1. 오류 데이터 생성 모듈

기본 바운딩박스에 통제된 오류를 자동으로 주입하고, 오류 유형과 강도별 학습 데이터셋을 생성한다.

2. 모델 학습·평가 모듈

각 오류 조건에서 동일한 초기 가중치와 학습 조건을 적용하여 객체탐지 모델을 학습하고, mAP, Precision, Recall 등의 성능지표를 수집한다.

3. 성능 패턴 데이터베이스

오류 유형과 강도에 따른 성능 변화를 저장하여, 검증 대상 데이터셋과 비교할 수 있는 기준 패턴을 구축한다.

4. 오류 가능성 분석 모듈

기준 패턴 데이터베이스를 활용해 오류 유형별로 가장 큰 성능 저하를 보이는 조건을 찾아 재검수 우선순위(높음/중간/낮음)를 매긴다. 현재는 기준 패턴 자체를 진단 예시로 제공하는 단계이며, 실제 고객 데이터셋을 업로드해 그 성능 벡터를 기준 패턴과 비교·매칭하는 기능은 다음 단계 구현 대상이다.

5. 품질검증 대시보드

데이터셋 품질점수, 오류 의심 건수, 성능 변화, 우선 재검수 대상을 시각적으로 제공한다.

6. 결과물

AIDA의 결과물은 데이터셋 품질점수, 오류 유형별 진단 리포트, 재검수 우선순위, 그리고 납품용 품질 인증서 초안 네 가지로 구성된다.

품질점수는 데이터셋 전체의 신뢰도를 0~100점으로 요약한 값이다. 일정 기준을 충족하면 품질 인증서 발급 대상이 되며, 기준 미달 시 "검토 필요" 상태로 표시된다.

오류 유형별 진단 리포트는 가로·세로 크기, 중심점 이동, 회전각, 스케일 등 오류 유형마다 기준 패턴 대비 최대 성능 저하율을 계산하고, 이를 근거로 재검수 우선순위(높음/중간/낮음)를 매긴다. 실측 결과 기준으로는 회전각 오류가 가장 큰 저하(mAP@0.5 5.7%↓)를 보여 재검수 우선순위가 가장 높게 나타났다. 다만 이 값은 100% 확정 진단이 아니라 확률적 추정이며, "재검수 자원을 어디에 먼저 투입할지"를 안내하는 가이드로 제공된다.

영향 지표로는 mAP@0.5, mAP@0.5:0.95, Precision, Recall 네 가지를 조건별로 함께 제시한다. 특히 Precision은 오류 조건에서도 거의 변하지 않는 반면 Recall은 뚜렷하게 하락해, 라벨 오류가 "오탐 증가"보다 "미탐 증가"로 먼저 나타난다는 점을 실측으로 확인했다. 여기에 원본 라벨과의 평균 IoU 감소율을 더해, 단순 퍼센트 강도보다 객관적인 오류 강도 지표를 함께 제공한다.

품질 리포트 예시는 위 항목들을 하나의 화면(대시보드) 또는 문서로 정리한 산출물이다. 데이터셋 기본 정보, 품질점수, 조건별 성능 변화 그래프, 오류 유형별 우선순위 표, 그리고 도입 시 절감 가능한 재검수 비용·GPU 재학습 비용 추정치(예시 시나리오 기준)를 함께 제공해, 발주처가 "왜 이 데이터셋을 재검수해야 하는지"를 근거와 함께 확인할 수 있도록 한다.

7. 고객 구조

AIDA의 1차 고객은 객체탐지 학습데이터를 발주하는 자율주행·모빌리티 비전 AI 기업과 완성차·부품사, 그리고 공공 AI 데이터 구축기관이다. 이들은 라벨링 업체로부터 데이터를 납품받지만, 실제 모델 성능이 낮아졌을 때 원인이 모델에 있는지 라벨에 있는지 구분할 근거가 없다는 문제를 안고 있다. AIDA는 이 발주처·AI 개발사에게 납품 데이터의 오류 가능성과 재검수 우선순위를 제시해, 무엇을 다시 검수해야 하는지 판단할 근거를 제공한다.

라벨링·데이터 구축 업체는 AIDA의 두 번째 고객이자 협력자다. 이들은 발주처가 요구하는 납품 조건을 충족해야 하는 입장이므로, 납품 전 AIDA의 품질검증 리포트를 제출해 품질을 스스로 증명하고 재작업

범위를 줄일 수 있다. 공공 AI 데이터 구축 사업에서는 이 수요가 이미 제도적으로 존재한다. 한국지능정보사회진흥원(NIA)이 주관하는 AI 학습용 데이터 구축사업은 TTA 품질지표 기준서에 따라 바운딩박스 정확도 등 정량 기준을 요구하고, 기준서 자체가 '제3자 품질검증'을 별도 절차로 명시하고 있다. AIDA는 이 기존 절차에 들어맞는 도구로 설계되어 있어, 새로운 시장을 만드는 것이 아니라 이미 존재하는 품질검증 수요에 맞춰 들어가는 구조다.

8. 사업모델

1. 검증 수수료

데이터셋 규모와 객체 수 기준으로 1회 품질검증 비용을 청구합니다.

2. 리포트 과금

납품용 품질 리포트와 인증서 초안은 별도 산출물로 과금합니다.

3. API / 프로젝트

반복 검수 고객에게 API 이용 계약 또는 프로젝트형 계약을 제공합니다.

AIDA의 수익 구조는 단발성 검증에서 반복 계약으로 단계적으로 확장한다. 초기에는 검증 대상 데이터셋의 규모와 객체 수를 기준으로 1회 품질검증 수수료를 받는다. 이는 발주처가 모델 재학습 1회에 들이는 비용보다 낮게 책정해 도입 문턱을 낮추는 것을 목표로 한다. 검증이 끝나면 납품용 품질 리포트와 인증서 초안을 별도 산출물로 제공하고, 이 리포트 발급에 추가 과금을 적용한다.

반복적으로 데이터셋을 검수해야 하는 고객에게는 프로젝트 단위 계약이나 API 연동 계약으로 전환한다. 발주처는 데이터 파이프라인에 AIDA API를 연동해 납품 시점마다 자동으로 품질검증을 받을 수 있고, AIDA는 이를 통해 건별 과금에서 사용량 기반 구독형 과금으로 수익 구조를 옮겨간다. 검증 수수료 → 리포트 과금 → API/프로젝트 계약으로 이어지는 이 구조는 고객이 AIDA를 처음 접하는 시점부터 장기 계약으로 전환되는 시점까지 자연스럽게 연결되도록 설계했다.

이후 자율주행·ADAS 분야에서 검증 사례와 오류 패턴 데이터를 축적한 뒤, 동일한 객체탐지 구조를 활용하는 로봇비전과 산업비전 분야로 적용 범위를 확장한다. 초기에는 자율주행 학습데이터를 중심으로 서비스의 정확도와 고객 효용을 검증하고, 이후 물류·배송 로봇, 서비스 로봇, 제조 불량 탐지, 스마트팩토리 안전관리 등 비전 AI 데이터 품질검증 수요가 존재하는 시장으로 확장할 계획이다. 이 과정에서도 1회 검증, 프로젝트 계약, API 연동의 수익 구조를 동일하게 적용하여 산업별 데이터 특성에 맞는 오류 패턴 DB와 품질검증 기준을 추가해 나간다. 즉, AIDA는 자율주행 특화 검증 서비스에서 시작해 다양한 비전 AI 산업의 데이터 품질을 관리하는 범용 플랫폼으로 성장하는 것을 목표로 한다.

9. 팀 역량 / 실행계획

팀 구성과 역할

박성원 — 대표 / 백엔드·인프라

FastAPI 기반 백엔드 구축, 실험 결과 연동, 시스템 문서화와 전체 프로젝트 운영을 담당한다.

김해연 — AI / 객체탐지

KITTI·YOLO 기반 실험 설계, 오류 조건별 모델 학습, 성능지표 수집과 결과 해석을 담당한다.

서정호 — 플랫폼 개발

데이터 파이프라인과 서비스 구조를 설계하고, 분석 결과가 실제 플랫폼 기능으로 연결되도록

구현한다.

정경준 — 프론트엔드

React 기반 대시보드와 시각화를 구현하여, 품질점수·오류 후보·재검수 우선순위를 사용자가 이해하기 쉬운 형태로 제공한다.

실행계획

2026년 7월 본선 이전

- OBB 도입 가능성 검토
- 복수 seed 기반 반복 실험
- 오류 조건별 성능 패턴의 재현성 확인
- 기존 MVP 화면과 분석 로직 정비

이 단계에서는 단일 실험 결과가 우연에 의해 발생한 것이 아닌지 확인하고, 오류 유형별 성능 패턴이 반복 실험에서도 유지되는지를 검증한다.

2026년 3분기

- 자율주행 샘플 데이터셋 기반 PoC 진행
- 고객이 실제로 활용할 수 있는 품질 리포트 양식 고도화
- 오류 후보와 재검수 우선순위 제공 방식 검증
- 초기 ROI 산정 기준 수립

이 단계에서는 공개 데이터 검증을 넘어, 실제 사용 시나리오에서 AIDA가 검수 범위를 얼마나 줄일 수 있는지를 확인한다.

2026년 4분기

- 베타 서비스 출시
- 라벨링 업체 및 AI 개발사 대상 파일럿 진행
- 사용자 피드백을 반영한 기능 개선
- 데이터 업로드, 분석, 결과 리포트 제공 흐름 통합

이 단계에서는 AIDA를 기술 실험이 아니라 실제 고객이 사용할 수 있는 서비스 형태로 전환한다.

2027년 상반기

- 유료 품질검증 계약 체결
- 프로젝트 단위 검증 서비스 운영
- API 연동 및 사용량 기반 과금 도입
- 반복 고객 중심의 장기 계약 구조 구축

최종적으로는 일회성 검증에서 시작해, 고객 데이터 파이프라인에 반복적으로 연결되는 품질관리 서비스로 확장하는 것이 목표다.

10. 마무리